赛题 2　信任守护师 - 创造者的 AI 卫士

欧莱雅 L'ORÉAL CHINA | 有意思青年 YOUTH FUN | 科技大FUN颂 BEAUTY TECHATHON

TruLens

Your AI Beauty Trust Agent

懂美妆生态的多模态 AI 鉴真专家

一个 Agent　四个信任维度　创作者自检 · 消费者核验

从多模态鉴伪、语义一致性校验，到处理建议的完整链条

Team No Five Days

“Before you trust beauty content, know its personality.”

在相信一篇美妆内容之前，先认识它的真实人格

支持单位：美创静界 BEAUTY NOVA TECH HUB | 阿里云 | 机器之心 Synced

OPENING

你还相信你看到的吗？

图文并茂，不再等于眼见为实。

66%

的消费者自信能识别 AI 生成的图片

但

57%

在实测中判断出错

种草文案，可以是 AI 写的

前后对比图，可以是 AI 修的

清一色好评，可以是灌出来的

数据来源： Clutch Survey, Sep 2025： 消费者 AI 图像识别能力调研

作品背景

1.1 · 行业与信任危机

增长靠内容，内容的信任却在被稀释

行业现状

2024–2030 美妆市场年增

3.8%

2030 年市场规模预计

867.2 亿美元

2025 年欧莱雅中国稳居国内美妆市场第一

数字化驱动：精准营销与内容体验，成为增长核心引擎

消费者怎么决策

线上种草 — 信任最脆弱的一环

↓

查测评

↓

比价

↓

线下试用

↓

电商下单

依赖多平台口碑交叉验证，每一步都在“选择相信谁”。

信任危机已经出现

35.7%

第三方测评账号涉嫌虚假测评

93.1%

测评不规范，存在商测一体问题

AI 虚假种草泛滥，人眼更难分辨

数据来源：欧莱雅集团 2025 年度美妆科技报告；毕马威《2025 中国美妆市场行业报告》； Clutch Survey, Sep 2025；中消协《第三方测评消费体验调查》

真假难辨，三方都在受伤

创作者

怕踩线，也怕被误伤

“我只想把产品讲清楚，却怕一不小心踩线。”

- 顺手写下“7 天变白”“100% 安全”等绝对化用语
- 真实内容被怀疑是 AI 或营销号，缺少申诉依据
- 优质内容被灌水内容挤压

TruLens： 发布前自检 + 申诉复核

消费者

看不出，也没处查

“这到底是真实分享，还是被包装出来的‘完美种草’？”

- 账号、图片、评论、文案都可能被包装
- 好评一边倒，真实反馈难与模板灌水区分
- 想核实，只能自己翻多篇笔记凭感觉对比

TruLens： 四维核验 + 交叉验证 + 处理建议

平台与品牌

审不过来，说不清依据

“内容太多，人工审核跟不上。”

- 海量 UGC 依赖人工审核，效率低
- 缺乏可解释的鉴真工具
- 虚假内容损害品牌信誉

TruLens： 团队版批量初筛，按风险排序

共同缺口：只有“结论”，没有“依据”

三方需要的不是“真假标签”，而是能解释原因的工具——如“检测到图片光影不一致”“评论区 12% 句式雷同”（示例）

图中表述为示例； TruLens 以创作者与消费者为主，向平台与品牌延伸。

场景分析

2.1 · 场景一 · 创作者

小雅发布前，先让 TruLens 替她查一遍

雅

小雅 · 28 岁

护肤博主，兼接品牌合作

想写得有说服力

怕无意踩线

真心想推荐好用的产品，却容易顺手写下“7 天变白”“100% 安全”这类绝对化说法。

核心需求

发布前自检：知道哪里要改、怎么改，并由自己决定是否采纳。

草稿 · 发布前

示例草稿

这款精华真的是我用过最有效的！**7 天直接变白①，敏感肌孕妇都能放心用，100% 安全无刺激②。别的都是智商税③**，闭眼入！





本次启用：文案真实性 S、图像原生性 R。账号、评论发布前暂无数据，不参与。

自检结果 · 示例

① **绝对化功效**

建议：个人使用约 7 天后感觉更好【X】，因人而异

采用建议　忽略

② **安全承诺缺依据**

建议：说明成分与适用人群，不做“100% 安全”承诺

采用建议　忽略

③ **贬损性引导**

建议：去掉对其他产品的贬损

采用建议　忽略

自检完成

披露清单 · 前后对比

记录“已完成发布前自检”（自检记录，非认证）

图中人物与笔记内容均为虚构示例，不涉及真实账号。

2.2 背景 · 场景二 · 消费者

小欧想买一瓶保湿精华：这一晚，她该相信谁？

欧

小欧 · 25 岁

职场新人，日常护肤上妆

预算有限　买前翻 20–40 分钟

小红书 + 抖音交叉对比

自信能分辨 P 图，面对 AI 生成的对比图和改写的文案，却极易判断失误。

核心需求

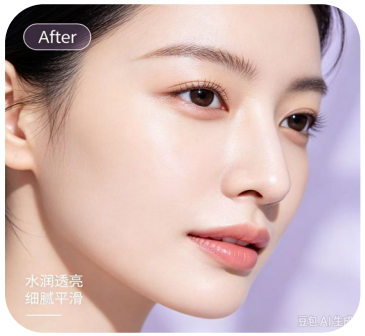
上传笔记，快速获得内容真实度评估，减少选购踩雷，辅助理性决策。

场景一 · 被“完美种草”吸引

某护肤博主　　示例笔记

25 岁女生一定要做好保湿！坚持 7 天，皮肤像鸡蛋一样嫩白





作为敏感肌，我用了这瓶精华一周，皮肤状态**直接提升一个 level**，姐妹们真的**闭眼冲！**

已经买第三瓶！

敏感肌狂喜！

评论区清一色好评

场景二 · 她开始怀疑

- 效果太完美
- 评论都像广告
- 文案像营销笔记

“这到底是真实分享，还是 AI 帮我创造出来的‘完美种草’？”

场景三 · 她打开 TruLens

丢进笔记链接。TruLens 不直接说“真”或“假”，而是说：

“让我看看，这篇内容的可信度画像。”

数据来源：毕马威《2025 中国美妆市场行业报告》；小红书公开社区帖子（仅作为项目参考）。图中笔记内容为示例，不涉及真实账号。

产品设计

3.1 · 产品定位与使用流程

TruLens：为每一篇种草，出一份信任画像

TruLens

Your AI Beauty Trust Agent

定位

面向美妆内容生态的多模态鉴真 Agent：消费者下单前核验别人的种草，创作者发布前自检自己的草稿；通过分析种草笔记中的帐号，图片，评论，文案，从四个信任维度核验、互相对质，给出带证据的 Beauty Trust Profile （美妆可信度画像）与建议。

一个 Agent | 四个视角 | 每个判断有证据 | 同一内核：消费者 · 创作者 · 团队版

用户使用流程

TruLens Agent 自动完成

1. **提交笔记** — 链接 · 文字 · 截图
2. **自动识别** — 启用对应维度
3. **四视角核验** — 账号 图片 评论 文案
4. **交叉验证** — 让四个发现互相对质
5. **Trust 报告与建议** — 分数 · 风险 · 建议
6. **追问或申诉** — 基于本篇继续问
7. **带着依据决策** — 买不买，自己定

3.2 · 产品特色

TruLens 的四个特色，一页总结

1

创作者与消费者，同一个内核

创作者发布前自检，消费者下单前核验：一个 Agent ，两端使用。

创作者 · 发布前自检

消费者 · 下单前核验

2

让四个发现，互相对质

不是四个工具拼在一起：维度两两交叉，标出文案、图片与账号之间的矛盾。



3

同一份判断，各有下一步

三档风险 × 消费者、创作者、平台、品牌方，给出具体可做的处理建议。

高风险　中风险　高可信

消费者　创作者　平台　品牌方

4

数据不足不硬判，可申诉

只评已有素材并标明置信度；不同意判断，可补充理由请它复核。

置信度 高　置信度 低

申诉 · 补充理由

主链路　多模态鉴伪 → 语义一致性校验 → 决策与建议

创意形式　四维对质　账号画像　置信度看板　对话式助手　场景覆盖与统一架构　创作者自检 × 消费者核验　分级风险策略　三档分级　按角色建议　带证据、可追问、可申诉

3.3 · 三段式链条

从鉴伪到决策：一条完整的三段式链条

01 多模态鉴伪

拆 + 查：各视角独立核验

T 账号
身份 · 推荐节奏 · 合作透明

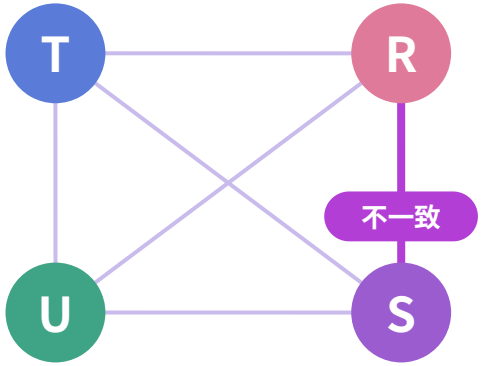
R 图像
光影 · 拼接 · 色彩过渡

U 评论
句式 · 发布时间 · 使用细节

S 文案
绝对化 · 夸大 · 模板口吻

02 语义一致性校验

合：让四个发现互相对质



N 个维度 → N(N−1)/2 组两两交叉

示例：文案称“7 天变白”，图片却露出修饰痕迹 → 标为不一致

03 决策与建议

三档分级 × 四种角色

高风险	暂缓 · 复核
中风险	留意 · 补充
高可信	参考 · 备查

对象：消费者 · 创作者 · 平台 · 品牌方

同一份判断，给不同的人不同的下一步

数据不足，不硬判：只对已启用维度交叉；仅 1 个维度时做维度内自洽；未启用的组合标“未核验”

第一段 · 多模态鉴伪：四个视角，各自核验



权重 15%

T

Trustworthiness

账号可信度

这个账号靠谱吗?

- 身份、地域与定位一致
- 历史内容垂直、稳定
- 推荐节奏、合作透明



权重 30%

R

Reality

图像原生性

这张图被动过吗?

- 光影与阴影是否一致
- 纹理、边缘、色彩过渡
- 有无拼接、磨皮痕迹



权重 20%

U

User Voice

评论自然度

这些评论是真的吗?

- 句式是否雷同
- 发布时间是否扎堆
- 有无真实使用细节



权重 35%

S

Script

文案真实性

这段文案夸大了吗?

- 有无绝对化功效与夸大
- 是否说明周期与个体差异
- 是否模板化、营销口吻

总分 = Σ （维度分 × 权重） · 只计算已启用的维度，未提供的素材不假设、不补全

3.5 · 第二段 语义一致性校验

第二段 · 交叉验证：让四个发现互相对质



产品实拍 · 52 分样本报告： 2 矛盾 · 1 佐证 · 3 存疑 → 提示「建议优先复核」

怎么对质

1. **两两配对** 已启用的 N 个维度 → N(N−1)/2 组， 4 维即 6 组
2. **比方向** 依据各维度可信分、风险等级与证据数量
3. **定关系** 输出关系状态 + 强度（低 / 中），可点开看依据

五种关系状态 矛盾 · 存疑 · 佐证 · 一致 · 未核验

矛盾	**可信方向不一致** 例：图片 100 × 文案 25
存疑	**存在明显分差，建议复核** 例：账号 65 × 评论 18
佐证	**两个维度指向同一方向，互相印证** 例：评论与文案同时报险
未核验	**缺少材料，明确保留、不硬比** 例：没有账号材料的 T 组

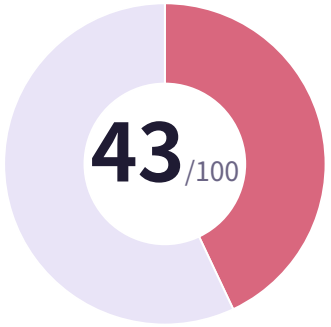
不硬判 另一篇缺账号材料的笔记： T 相关 3 组标为「未核验」，其余 3 组互相佐证 → 「已启用维度相互印证，暂未发现矛盾」

3.6 · 信任画像与证据链

不是“真”或“假”，而是一份可点开的信任画像

TRUST SCORE

界面示意 · 示例数据



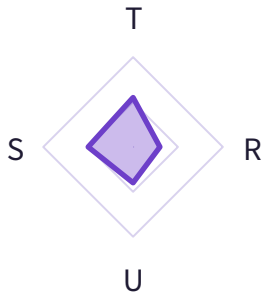
高风险　置信度 高

多处依据偏弱，建议谨慎参考

本次结论仅基于已提供的素材（4 个维度均已核验）



高风险　　可信



T	账号可信度	55
R	图像原生性	30
U	评论自然度	40
S	文案真实性	50

每个分数，都能点开证据链

原始信号 → 模型判断 → 评分结论

T	**账号**	标出推荐密度偏高的历史笔记
R	**图片**	标注可疑区域（示意） · 依据：光影 / 拼接 / 色彩过渡
U	**评论**	归组句式雷同的评论（示例： 12% 雷同）
S	**文案**	高亮夸大表述的句子

追问
基于本篇继续问，回答标明所用维度

申诉
不同意？补充理由，判断可被复核

技术透视
查看每项判断来自大模型还是规则

第三段：同一份判断，给不同的人不同的下一步

	消费者 下单前	创作者 发布前	平台 审核初筛	品牌方 合作与监测
高风险	暂缓下单，先看证据；对照其他来源再决定	建议修改后再发布，补充真实使用素材	进入人工复核队列，必要时限流观察	暂缓合作或投放，先核实素材来源
中风险	可参考，但留意被标出的几处疑点	改掉夸大表述，补充周期与个体差异说明	加提示标签，纳入抽检	要求补充材料后再推进合作
高可信	可作为参考之一，仍建议多源对比	可发布；保留原图与过程素材备查	正常分发，持续抽检	可纳入合作候选，保留核验记录

辅助决策，不构成购买建议或定性结论 · 输入不足 4 个维度时，首条建议为“补充材料”

3.8 · 场景覆盖

同一套内核，三种使用方式

创作者 · 发布前自检

聚焦文案 S+ 图像 R

- 句子级问题卡：采用建议 / 忽略
- 需补充处用【X】占位，不替创作者编造
- 披露清单 · 三态结论 · 前后对比
- 完成得“已完成发布前自检”标记（自检记录，非认证）

消费者 · 下单前核验

种草笔记 → 信任画像

- 输入链接 · 文字 · 截图
- 四维核验 + 交叉验证 + 处理建议
- 追问、申诉、技术透视

团队版 · 批量初筛

面向品牌方 / 平台

- 批量队列：TRUS 四点亮，一眼看出覆盖维度
- 抽屉看详情、批量标记
- 风险分布 · 置信度分布
- 关联分组：相似内容聚类（规划）

不是三个产品，而是同一个 Agent：创作者发布前自检，消费者下单前核验，团队批量初筛

核心功能演示

4. 核心功能

一次完整鉴别：从丢进笔记，到有依据的下一步

TruLens 把链接、文案与图片拆成 T/ R/U/ S 四类信号，由四位角色并行核验，再通过交叉关系形成可解释的报告和分角色建议。

01 提交与识别
CAPTURE

待核验内容

粘贴小红书链接、正文或截图
系统正在识别可用材料

本次启用维度 自动识别

T R U S

缺少材料的维度会明确显示「暂不评分」，不参与加权总分。

上传、识别、确认材料范围
从第一步建立可核验的证据边界

02 多角色分析
REASONING COUNCIL


账号侦探 ACCOUNT HISTORY 已核验


视觉取证师 IMAGE SIGNALS 已核验


口碑观察员 COMMENT PATTERNS 低可信


文案检查官 CLAIM EVIDENCE 需核验

四位角色并行分析 过程可追踪

账号、图片、评论与文案独立判断
再进入一致性校验

03 报告与交叉验证
CROSS-CHECK

52/100 存疑

置信度 高 · 4/4 维

T 65
R 100
U 18
S 25

交叉验证关系 2 矛盾 · 1 佐证

T × S · 账号与文案方向不一致 矛盾

R × U · 图片与评论可信度分差 存疑

R × S · 视觉与文案同步报险 佐证

分数不是终点
维度之间的关系才是判断依据

04 证据与分角色建议
EVIDENCE & ACTION

消费者 创作者 平台运营 品牌方

R 图片局部修饰 重点
肤质纹理与光影不一致

S 绝对化功效表达 重点
结论缺少可追溯来源

U 评论话术同质化 风险
短评重复与发布时间接近

CONSUMER NEXT STEP
暂缓依据该内容下单，先核对原图、合作披露与独立使用反馈。

点击任一维度查看证据链
同一份报告给出四类角色的下一步

现场演示：消费者主线走完“提交 → 分析 → 报告 → 追问”，再切到创作者发布前自检（图为界面示意，数据为示例）

技术实现方式

5.1 系统架构：
从上传到报告的完整数据流

展示层
Web 前端

React+Vite | 四角色分析 | 四维报告 | 证据链 | 决策建议 | 追问 / 申诉 | 创作者自检 | 团队版

服务层
后端 API

FastAPI | 任务 / 报告 / 样本 / 团队 / 创作者 / 引擎轨迹 API | 原始素材存储 | 会话上下文（task ID）

Agent 层
核心

输入识别 → 维度路由 → 四维核验 → 交叉验证 → 评分 · 置信度 → 分级建议

模型层
大模型 + 规则

DeepSeek Flash： 负责 S/U/T 与解释

GLM-5.3-FlashX: R 与图文一致性

Qwen-VL： 仅作备用

数据层
数据与评估

SQLite 开发 /PostgreSQL 生产 | 上传文件、任务、报告、轨迹 | 探测性测试包与自动化评估

数据流向：用户上传 → Agent 分析 → 报告生成 → 追问复用任务上下文

统一架构覆盖四类对象：账号画像（T） · AI 素材（R） · 评论区（U） · 种草文案（S）

Agent 如何决策：识别、核验、对质、评分、给建议

1 **接收输入**
链接 · 文字 · 截图
保存原始素材

2 **识别选维**
判断输入类型
启用对应维度

3 **多维核验**
各维度独立
百分制打分

4 **交叉验证**
维度两两对质
标出不一致

5 **评分与分级**
加权评分 · 置信度
对照阈值分档

6 **建议与报告**
四角色处理建议
证据链与报告

追问：绑定原任务 ID，复用原始素材、各维度分数、报告全文与推理记录，回答标明所用维度

维度如何自动选择

帖子链接	T R U S	跳转对应内容
截图	T R U S	识别画面，按内容匹配
纯复制文本	S	仅评文案
图片 + 文本	R S	按提供的素材启用

开启哪些维度，就只计算哪些维度。

评分机制

总分 = Σ（维度分 × 权重）

帐号 15%	图片 30%	评轮 20%	文案 35%

示例： 55×15% + 30×30% + 40×20% + 50×35% ≈ 43

总分对照阈值分档，并给出置信度；输入的维度越少、证据越少，置信度越低。

数据集样本评估

用数据说话： 22 条自建高仿样本， 6 条真实接口实测

下方以综合样本 sample_011 为例：一条笔记覆盖 5 类场景

S 文案层 · S01–S07 · 7 处

AI 生成种草文案

无出处功效数据、绝对化安全宣称（孕妇可用）、「无广自费」软广伪装

R 图片层 · S08–S16 · 9 处

AI 生成 / 伪造图片与截图

同图调色冒充 28 天对比、聊天截图时间倒置、柱高与数值不符

U 评论与凭证 · S17–S22 · 6 处

刷评与伪造凭证

11 秒内 7 条模板好评、客服小号进评论区、 4.9 分却有 67 条 1 星

! 高区分度 · 必须命中

4 处关键疑点

S08 同图调色 · S11 时间戳倒置
S14 柱高不符 · S17 11 秒刷评

5 类场景全覆盖：内容全部为合成，标注真值为「伪造 · 高风险」

种草正文 +9 张配图 | 评论区 + 商品评论 | 客服投诉记录

怎么评估

1 **逐条比对**

模型输出 {id, hit, reason} ，与 labels.json 的 22 处疑点逐条对照

2 **召回与误报**

召回率 = 命中数 / 22 ；标注之外报出的疑点计为误报；合格线 ⩾ 11 处

3 **结论与闭环**

判定须为「伪造 · 高风险」，建议覆盖限流、索要原件、风控标记与保留申诉

实测结果 6 条 · 易 / 中 / 难 + 对照

伪造样本判为中 / 高风险： **3 / 5**
风险档位完全命中： **1 / 5** （ sample_012 ）
对照样本误报： **0 / 1** （ sample_029 判为低风险）
漏判 011 、 014 ，原因已初步定位，列入短期优化

让四类角色，从「凭感觉相信」到「有依据地信任」

消费者
环节：下单前

TA 在问
这篇种草，真的能信吗？

TruLens 给什么
- 点开分数，看到证据链
- 按维度给出下单前建议

带来的价值
少踩雷，钱花在真口碑上

创作者
环节：发布前

TA 在问
真心推荐，会被当软广吗？

TruLens 给什么
- 发布前自检，句子级改写
- 披露清单 + 申诉通道

带来的价值
真实内容不被误伤

平台
环节：审核初筛

TA 在问
这么多笔记，先看哪条？

TruLens 给什么
- 批量队列与风险分级
- 每条结论附可复核证据

带来的价值
人工只盯高风险内容

品牌方
环节：合作与监测

TA 在问
挂我名的功效宣称属实吗？

TruLens 给什么
- 合作前批量核验达人内容
- 监测挂名的夸大与伪造宣称

带来的价值
守住品牌信誉与合规底线

落地路径

Web 原型 → 浏览器插件 / 小程序 → 开放 API

- 人机协同，不替代审核：每个结论都可追问、可申诉、可复核
- 试点后用真实数据衡量：初筛耗时 · 申诉改判率 · 建议采纳率 · 召回与误报

从一个 Demo，到美妆内容的信任基础设施

短期 可信可测

把每一次判断做得可验证

- 测试集扩为成批高仿样本，分难度档，公开召回率与误报率
- 图片疑点从区域示意升级为精确框选
- 打通实时分析全链路，界面区分示例 / 实时
- 人工复核结果回流，持续校准评分与置信度

衡量：召回率 · 误报率 · 置信度校准

中期 产品化

走进用户刷到种草的那一刻

- 浏览器插件 / 小程序：刷到即核验，免复制粘贴
- 已核验内容库：相似文案与图片比对，识别矩阵号与批量水军
- 视频与直播切片解析，覆盖美妆种草主战场
- 团队版：关联分组、置信度分布、审核留痕

衡量：核验量 · 采纳率 · 申诉改判率

长期 生态共建

让「有依据的信任」成为行业默认

- 开放 API：让可信依据成为内容社区的基础标签
- 与品牌、 MCN 、平台共建真实内容认证与创作者信用
- 跨平台内容溯源；个性化信任偏好

衡量：接入方数量 · 认证内容占比

SUMMARY

在相信一篇美妆内容之前，先看清它的依据

替创作者发布前先查一遍，替消费者下单前再查一遍：守住那份看得见、信得过的真实。



看得见

每个分数都能点开：文案高亮、区域示意、评论归组



信得过

数据不足不硬判，只评已有素材，并标明依据与置信度



可追问

追问、申诉、给出按角色区分的下一步，判断不是终点

TruLens • Your AI Beauty Trust Agent

Team No Five Days • 赛题 2 信任守护师 - 创造者的 AI 卫士

欧莱雅 L'ORÉAL CHINA | 有意思青年 YOUTH FUN | 科技大FUN颂 BEAUTY TECHATHON

THANKS!

支持单位：美创静界 美妆健康创新生态社区 BEAUTY NOVA TECH HUB | 阿里云 | 机器之心 Synced